SYSTEMY SZTUCZNEJ INTELIGENCJI · PROJEKT ZALICZENIOWY

Analiza i prognoza meczów tenisa ATP

Czyszczenie danych, analiza eksploracyjna, ranking Elo oraz trzy modele uczenia maszynowego na zbiorze 16 105 meczów z lat 2021–2026

Autorzy

Mateusz Wasyluk · Kacper Dobrowolski · Mikołaj Zdunek

Rok akademicki

2026/2027

Cel projektu i pytania badawcze

PYTANIE 1

Co decyduje o wyniku meczu?

Czy własny ranking formy przewiduje zwycięzcę lepiej niż oficjalny ranking ATP?

PYTANIE 2

Od czego zależy liczba asów?

Jaki udział mają nawierzchnia, wzrost serwującego i cechy przeciwnika?

PYTANIE 3

Jakie style gry istnieją?

Czy algorytm sam wyodrębni grupy zawodników, bez podawania mu definicji?

Każde pytanie prowadzi do innego typu modelu uczenia maszynowego: klasyfikacji, regresji i klasteryzacji.

Dane źródłowe

16 105
surowych meczów

6
sezonów: 2021–2026

724
zawodników w rankingu

49
kolumn w surowym pliku

Co zawiera jeden rekord

- nazwiska, rankingi ATP, wzrost, ręka zawodników
- nawierzchnia, turniej, data, wynik setowy
- asy, podwójne błędy, punkty serwisowe
- trafione pierwsze serwisy, break pointy

Dwa zbiory wynikowe

Mecze	Do czego służą
15 561	ranking Elo i model zwycięzcy — wystarczy wiedzieć, kto kogo pokonał
14 648	analiza serwisu, model asów i style gry — wymagają kompletu statystyk

Przy 913 meczach brakuje statystyk serwisowych w samym źródle. Zamiast je odrzucać, oddzielamy dwa zbiory.

Źródło: Jeff Sackmann, zbiór tennis_atp (mirror archiwalny) · licencja CC BY-NC-SA 4.0

INŻYNIERIA DANYCH

Dokładanie nowych meczów

Zbiór Sackmanna kończy się w maju 2026. Żeby domknąć sezon, dołączamy dane z drugiego źródła — ale oba zapisują mecze inaczej, więc trzeba je pogodzić.

Rozpoznanie formatu

Skrypt sam wykrywa, z jakiego źródła pochodzi plik, patrząc na nazwy kolumn, i tłumaczy je na nasz format.

Dopasowanie nazwisk

„Djokovic N." to ten sam zawodnik co „Novak Djokovic". Algorytm usuwa akcenty i radzi sobie z nazwiskami dwuczłonowymi.

Uzupełnienie braków

Nowe źródło nie podaje wzrostu ani ręki. Bierzemy ostatnią znaną wartość z meczów, które już mamy.

Odrzucenie duplikatów

Ten sam mecz w obu źródłach może mieć inną datę, bo jedno podaje początek turnieju. Porównujemy parę zawodników w oknie 14 dni.

Dlaczego to nie trafia do analizy serwisu

Drugie źródło nie zawiera asów ani punktów serwisowych. Nowe mecze zasilają więc **wyłącznie ranking Elo i model zwycięzcy**, a zbiór do analizy serwisu zostaje nietknięty. Mieszanie ich zaniżyłoby średnie.

ETAP 1 · CZYSZCZENIE DANYCH

Normalizacja statystyk serwisu

$$\text{asy na 100 punktów} = \text{liczba asów} \div \text{punkty serwisowe} \times 100$$

Analogicznie liczymy podwójne błędy oraz procent trafionych pierwszych serwisów.

Dlaczego nie surowa liczba asów

Mecz pięciosetowy daje dwa razy więcej okazji na asa niż trzysetowy. Bez przeliczenia model uczyłby się przede wszystkim, że **dłuższe mecze mają więcej asów** — czyli prawdy bezużytecznej.

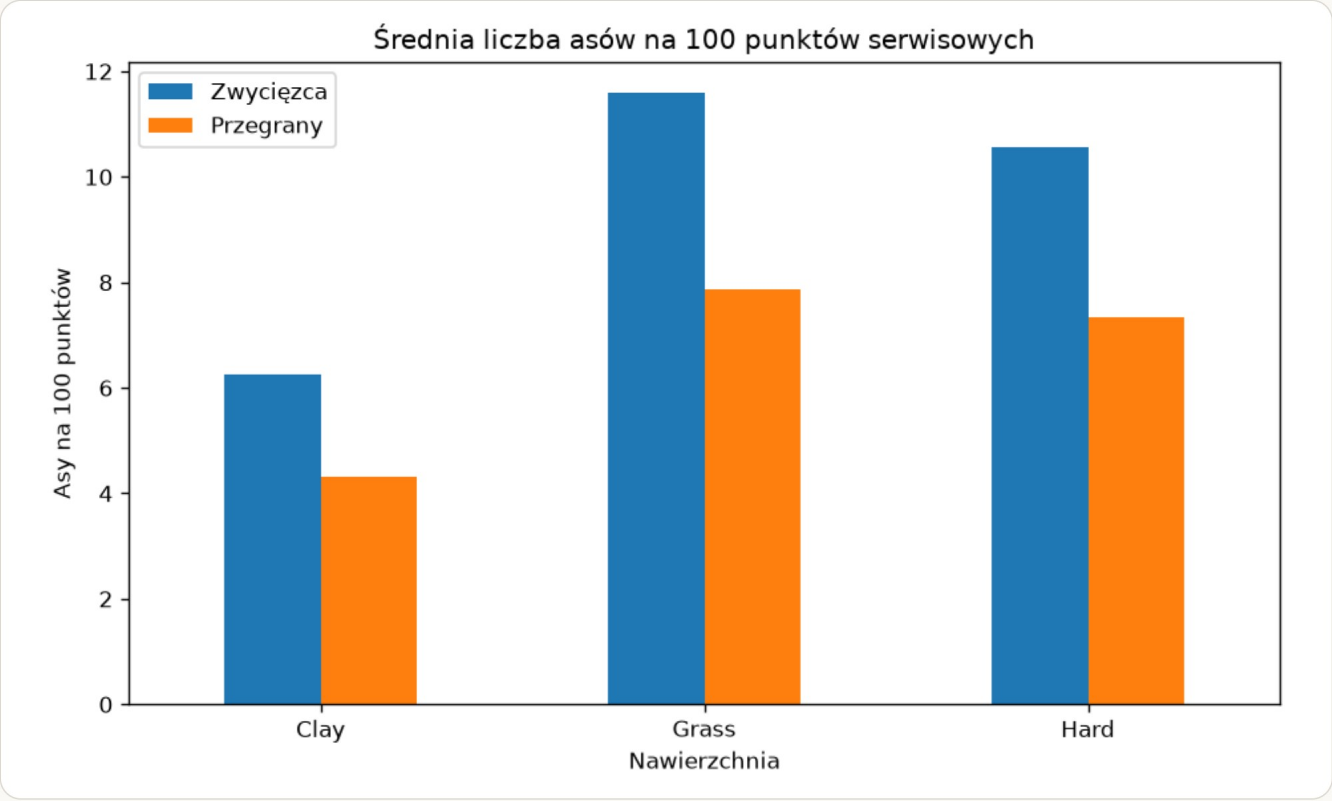
Przykład z naszych danych

Asy	Punkty serw.	Wskaźnik
14	81	17,3
11	63	17,5

Surowo różnica wygląda na dużą. Po normalizacji widać, że serwis był niemal identyczny.

ETAP 2 · ANALIZA EKSPLORACYJNA

Nawierzchnia a liczba asów



Trawa

11,6

asa na 100 punktów

Kort twardy

10,6

asa na 100 punktów

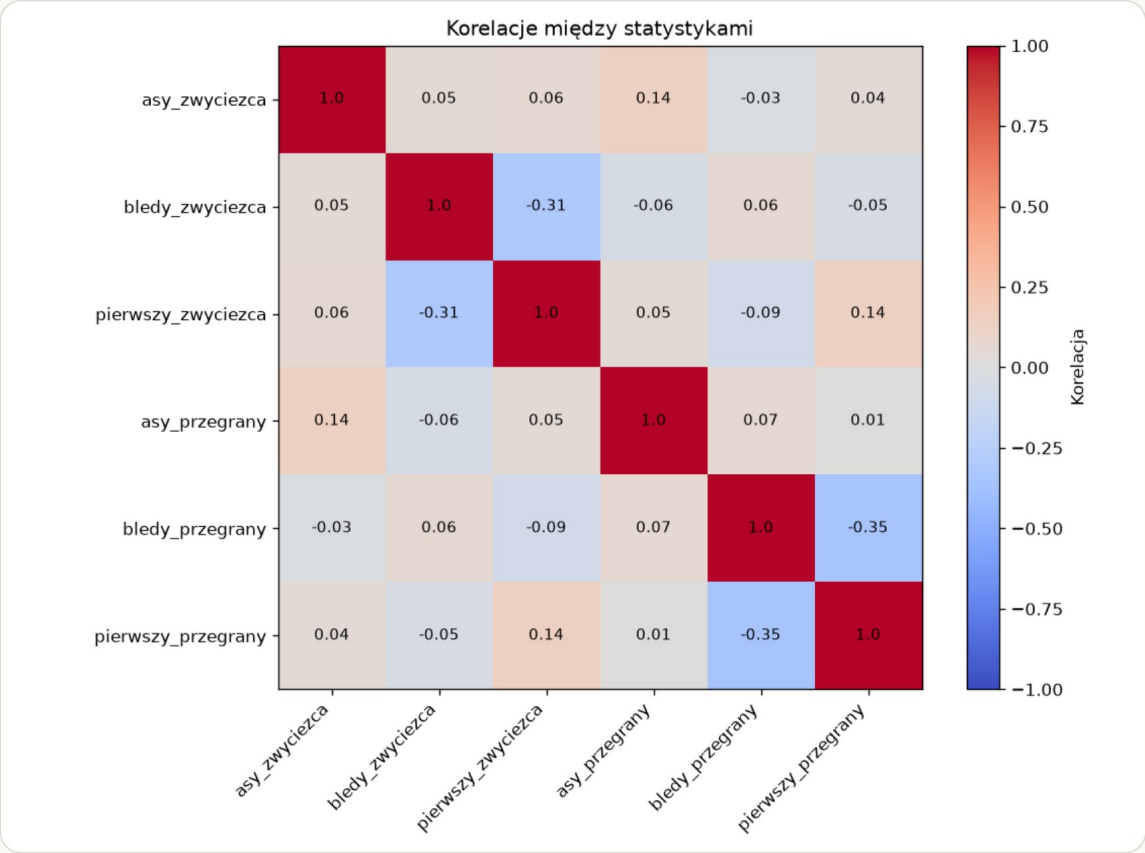
Mączka

6,3

asa na 100 punktów

Wartości dla zwycięzców meczów · n = 14 650

Korelacje między statystykami



Jak czytać

Wartości od −1 do 1. Bliżej zera oznacza brak zależności liniowej, znak mówi o kierunku. Na przekątnej zawsze 1.

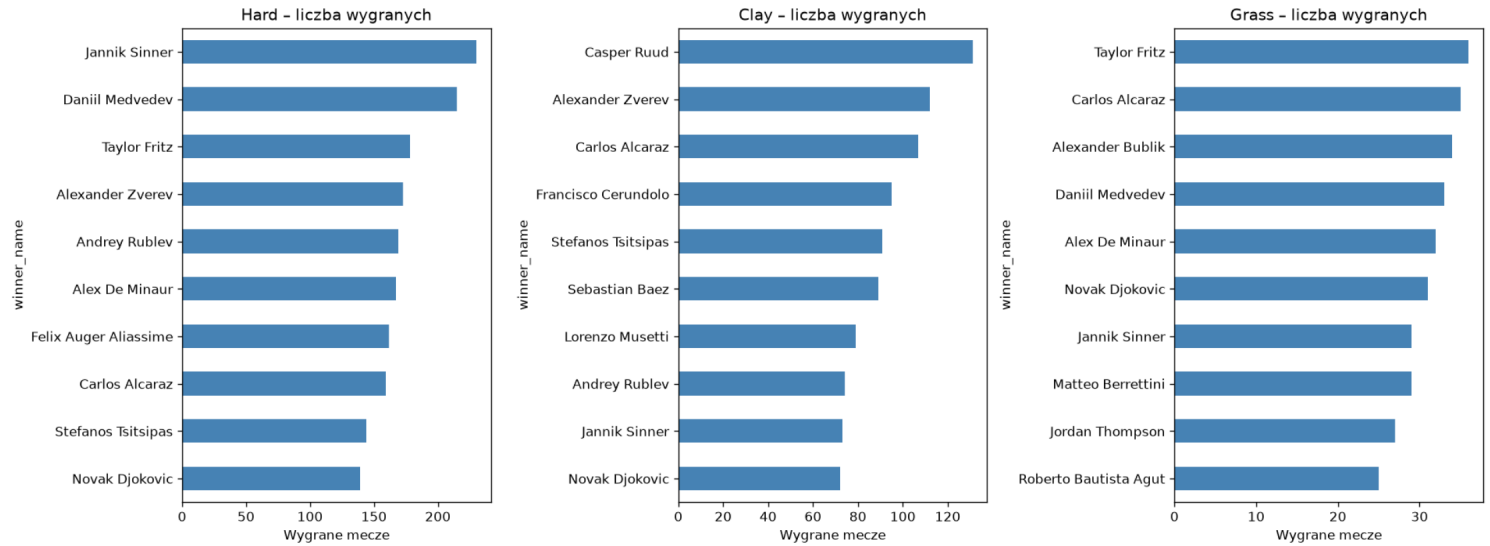
Najsilniejszy związek

−0,31 do −0,35

między procentem pierwszego serwisu a podwójnymi błędami: kto częściej trafia pierwsze podanie, rzadziej musi ryzykować drugim

Korelacja mierzy wyłącznie zależność liniową i nie dowodzi przyczyny.

Specjalizacja nawierzchniowa



Kort twardy

Sinner i Miedwiediew wyraźnie przed resztą — to nawierzchnia z największą liczbą turniejów.

Mączka

Zupełnie inna czołówka: Ruud, Cerúndolo i Báez, którzy na innych nawierzchniach nie wchodzą do dziesiątki.

Trawa

Najkrótszy sezon i tylko 1 540 meczów, więc liczby są niższe, a ranking mniej stabilny.

Liczba wygranych meczów w latach 2021–2026

ETAP 3 · WŁASNA MIARA FORMY

Ranking Elo

Oczekiwana szansa zawodnika A

$$SA = 1 \div (1 + 10(EloB - EloA) \div 400)$$

Przy równym Elo wychodzi 0,5. Przewaga 400 punktów daje około 10 do 1.

Zmiana po meczu

$$\Delta = K \times (1 - Szwycięzcy), K = 32$$

Zwycięzca zyskuje dokładnie tyle, ile traci przegrany. Start: 1500 punktów.

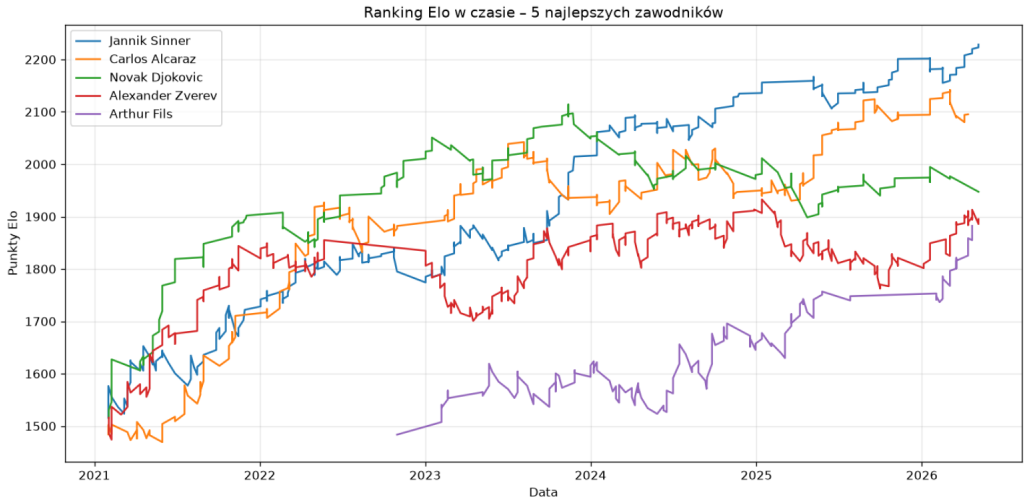
Niespodzianki ważą więcej

Faworyt z 90% szans zyskuje za wygraną **3,2** punktu. Outsider z 10% szans zyskuje **28,8**. Algorytm mocniej koryguje ocenę, gdy się pomylił.

Czym różni się od rankingu ATP

Ranking ATP sumuje punkty za turnieje z ostatnich 12 miesięcy i nie patrzy, z kim się grało. Elo aktualizuje się po każdym meczu i uwzględnia siłę przeciwnika.

Elo w czasie: zmiana pokoleniowa



Czołówka Elo na koniec zbioru	Punkty
Jannik Sinner	2 228
Carlos Alcaraz	2 095
Novak Đoković	1 947
Alexander Zverev	1 895
Arthur Fils	1 882

Co widać na wykresie

Đoković prowadzi do końca 2023 roku, po czym jego krzywa opada, a Sinner i Alcaraz systematycznie rosną. Elo wychwyciło tę zmianę **szybciej niż ranking ATP**, bo reaguje po każdym meczu, a nie po cyklu turniejowym.

ETAP 4 · UCZENIE MASZYNOWE

Jak uczy się model

1

Cechy i odpowiedź

Mecz zamieniamy na zestaw liczb oraz odpowiedź, której szukamy.

2

Trenowanie

Model zgaduje, porównuje z prawdą i koryguje wagi. Tysiące powtórzeń.

3

Testowanie

Sprawdzamy na meczach, których model nigdy nie widział.

4

Punkt odniesienia

Wynik porównujemy z rzutem monetą albo zgadywaniem średniej.

Podział danych po czasie, nie losowo

Model uczy się na 80% najstarszych meczów, a sprawdzamy go na 20% najnowszych. Podział losowy pozwoliłby mu uczyć się na grudniu i odpowiadać o styczniu — czyli znać przyszłość. Po zmierzeniu jakości model douczamy na komplecie danych.

MODEL 1 · KLASYFIKACJA · REGRESJA LOGISTYCZNA

Kto wygra mecz?

Porównanie trzech wariantów

Cechy podane modelowi	Dokładność
Tylko ranking ATP	64,79%
Tylko Elo	65,10%
Wszystko razem	65,10%
Rzut monetą (odniesienie)	50,00%

Test na 20% najnowszych meczów, których model nie widział podczas uczenia.

Cechy modelu

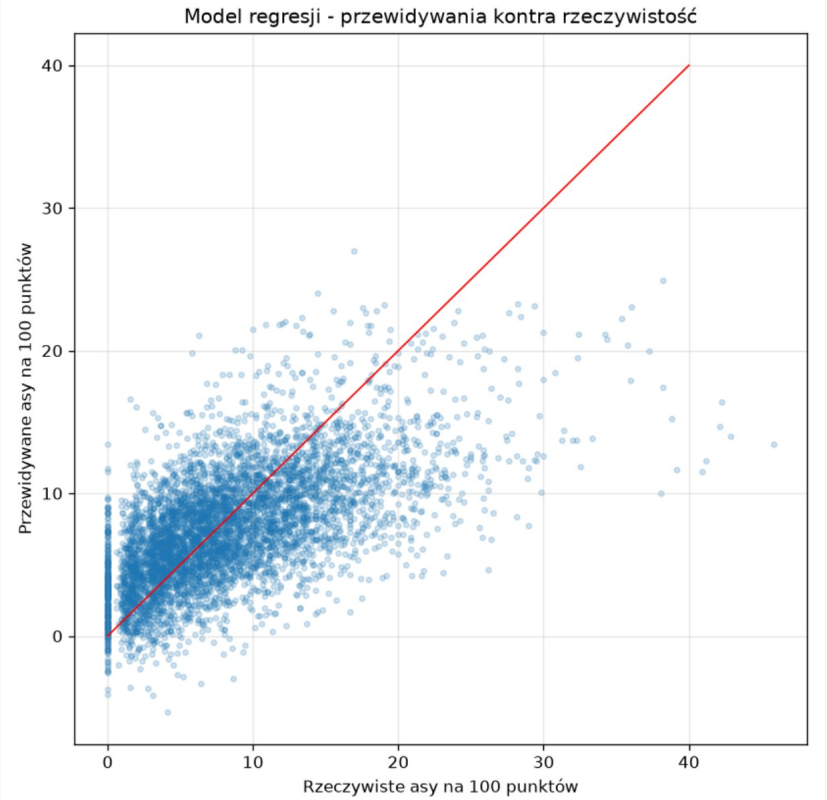
- różnica Elo ogólnego
- różnica Elo na danej nawierzchni
- różnica rankingu ATP
- różnica wzrostu
- rodzaj nawierzchni (kodowanie 0/1)

Wniosek

Elo wypada minimalnie lepiej niż ranking ATP, ale dodatkowe cechy nie poprawiają już wyniku — informacja o sile zawodników jest w Elo zawarta.

MODEL 2 · REGRESJA · REGRESJA LINIOWA

Ile asów zrobi serwujący?



Inny typ odpowiedzi

Klasyfikacja odpowiada „kto wygra" — tak albo nie. Regresja odpowiada **„ile"**, czyli zwraca liczbę. Z jednego meczu robimy dwa wiersze: raz serwuje zwycięzca, raz przegrany.

Cechy

historia serwisu zawodnika · podatność przeciwnika na asy · wzrost obu · ręka przeciwnika · jego ranking · nawierzchnia

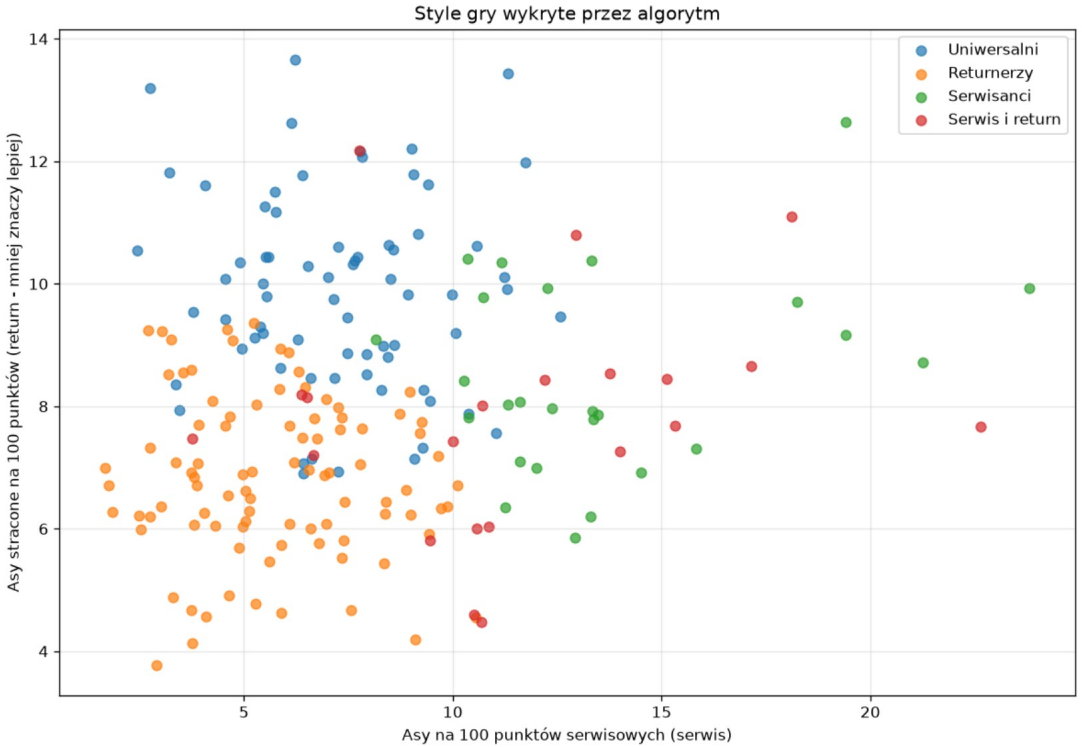
Zabezpieczenie

Średnie historyczne liczymy **wyłącznie z okresu uczenia**. Policzone z całości zawierałyby mecze ze zbioru testowego, a model znałby przyszłość.

Czerwona linia oznacza idealne trafienie; im bliżej niej punkty, tym lepszy model

MODEL 3 · UCZENIE NIENADZOROWANE · KMEANS

Style gry wykryte przez algorytm



Algorytm nie dostaje **żadnych etykiet**. Sam dzieli 210 zawodników na grupy, porównując cztery cechy: asy, podwójne błędy, procent pierwszego serwisu i asy tracone przy returnie.

Skalowanie przed analizą

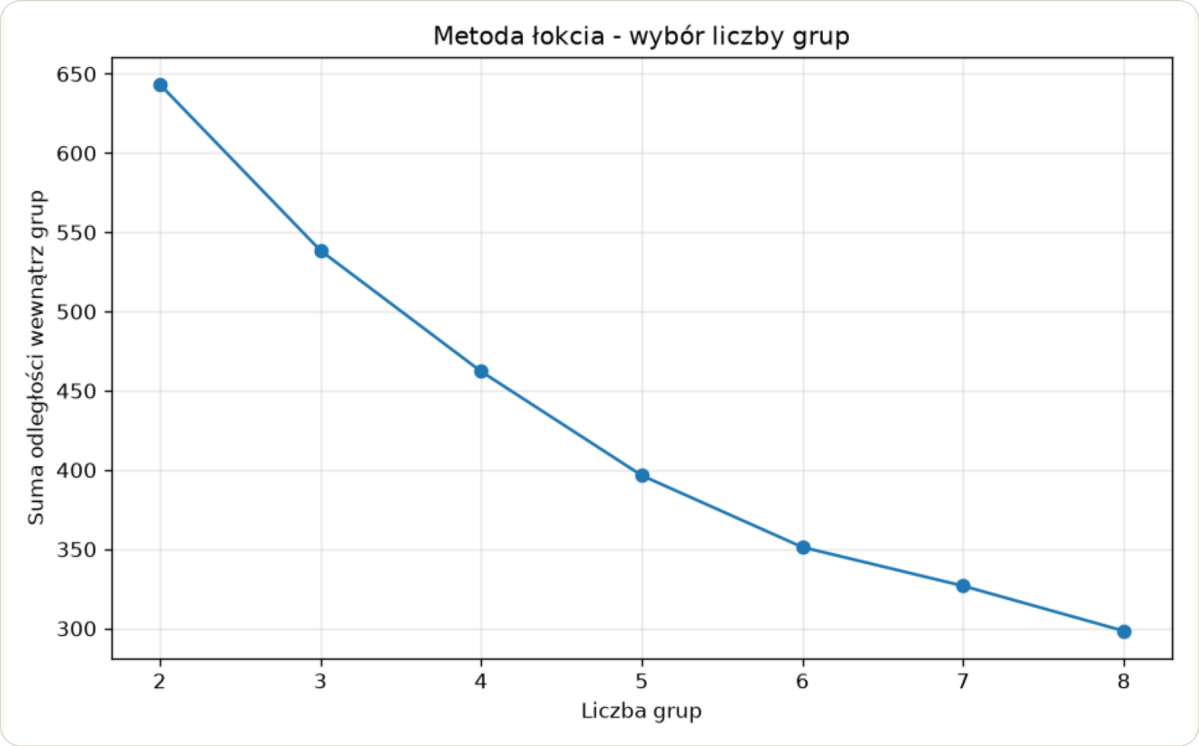
Asy mają wartości rzędu 10, a procent pierwszego serwisu rzędu 62. Bez skalowania algorytm patrzyłby wyłącznie na większe liczby.

Nazwy nadaliśmy my

Algorytm zwraca wyłącznie numery grup. Etykiety przypisujemy automatycznie, badając położenie środka grupy wobec średniej na osi serwisu i returnu.

Serwisanci: Isner 23,8 · Raonic 22,6 · Opelka 21,3 asa na 100 punktów · minimum 30 meczów

Metoda łokcia: ile grup wybrać



Problem

Suma odległości wewnątrz grup **zawsze** maleje, gdy dodajemy grupy. Przy liczbie grup równej liczbie zawodników spadłaby do zera — każdy byłby sam. Idealny wynik, zerowa wartość poznawcza.

Rozwiązanie

Patrzymy na **kształt** krzywej, nie na wartość. Spadek stromy oznacza, że nowa grupa realnie rozdziela różnych zawodników. Wypłaszczenie — że tylko kroi spójne skupiska.

Nasz wybór

k = 4 grupy

ETAP 5 · PRODUKT KOŃCOWY

Aplikacja webowa

Interfejs w Streamlit wczytuje wytrenowane modele i rankingi. Użytkownik wybiera dwóch zawodników i nawierzchnię, a aplikacja pokazuje prognozę oraz pełny kontekst statystyczny.

Prognoza

szansa na wygraną z modelu, zestawiona z wynikiem samego wzoru Elo

Profil zawodnika

statystyki ogółem i osobno dla każdej nawierzchni

Bezpośrednie mecze

bilans i porównanie formy przeciwko temu rywalowi z resztą sezonu

Style gry

role zawodnika i jego przynależność procentowa do grup

Uczciwe traktowanie braków

Jeśli zawodnik nie rozegrał meczu na wybranej nawierzchni, aplikacja pokazuje **„brak danych”**, a nie wartość startową 1500. Przy mniej niż pięciu meczach wyświetla ostrzeżenie, że prognoza jest niepewna.

Wnioski i ograniczenia

Co udało się pokazać

- Elo przewiduje zwycięzcę nieco lepiej niż ranking ATP i znacznie szybciej wychwytuje zmianę formy
- Nawierzchnia silnie wpływa na liczbę asów: trawa daje ich niemal dwa razy więcej niż mączka
- Algorytm bez podpowiedzi wyodrębnia style gry zgodne z intuicją kibica
- Dodatkowe cechy nie poprawiły modelu — informacja była już zawarta w Elo

Czego model nie potrafi

- W danych nie ma kierunku ani rodzaju serwisu, ustawienia returnera, podziału na halę i kort otwarty
- Bilans bezpośrednich meczów nie wchodzi do modelu: większość par zagrała ze sobą 0–3 razy
- Styl gry to interpretacja podobieństwa statystyk, nie pomiar zachowania na korcie
- Prognoza nie uwzględnia formy dziennej, zmęczenia ani kontuzji

Kierunki rozwoju

Połączenie z danymi tennis-data.co.uk pozwoliłoby uwzględnić podział hala / kort otwarty oraz porównać skuteczność modelu z kursami bukmacherskimi na kilku tysiącach meczów historycznych.

Dane: Jeff Sackmann, zbiór tennis_atp · licencja CC BY-NC-SA 4.0